



آمار و احتمال مهندسی

Engineering Probability & Statistics

Lecture Notes ■ جزوه درسی

ماژول ۱۱

قضیه حد مرکزی

Central Limit Theorem

استاد: امین آذری


گردآوری شده توسط: آیدین شکاری

Instructor: Amin Azari github.com/AminAzari

$n = 1$

$n = 2$

$n = 30$



فهرست مطالب این ماژول

۳	۱۱.۱ مقدمه: چرا گاوسی همه جا هست؟
۴	۱۱.۲ قانون اعداد بزرگ (LLN)
۵	۱۱.۳ قضیه حد مرکزی (CLT)
۶	۱۱.۴ نرخ همگرایی
۷	۱۱.۵ نمایش بصری
۸	۱۱.۶ اهمیت مهندسی
۹	۱۱.۷ نمایش‌های مونت کارلوی MATLAB
۱۲	۱۱.۸ تقریب‌زنی با استفاده از CLT
۱۳	۱۱.۹ مسایل تمرینی

اهداف یادگیری

پس از تکمیل این ماژول، دانشجویان قادر خواهند بود:

۱. قانون اعداد بزرگ را بیان و توضیح دهند
۲. قضیه حد مرکزی را بیان و به کار ببرند
۳. توضیح دهند چرا توزیع‌های گاوسی این قدر در مهندسی فراوان‌اند
۴. از CLT برای تقریب‌زنی استفاده کنند
۵. CLT را به صورت بصری با شبیه‌سازی‌های مونت کارلوی MATLAB نشان دهند

۱۱.۱ مقدمه: چرا گاوسی همه جا هست؟

توزیع گاوسی در موارد زیر ظاهر می‌شود:

► نویز حرارتی، خطاهای اندازه‌گیری، رواداری‌های ساخت، تداخل تجمعی، نوسان‌های سهام

دلیل: همه این کمیت‌ها جمع‌ها (یا میانگین‌ها)ی بسیاری از اثرهای تصادفی کوچک و مستقل هستند. CLT همگرایی به گاوسی را صرف‌نظر از توزیع زیربنایی تضمین می‌کند.

۱۱.۲ قانون اعداد بزرگ (LLN)

■ قانون ضعیف اعداد بزرگ

برای $X_1, X_2, \dots, X_n$ مستقل و هم‌توزیع (i.i.d.) با میانگین μ و واریانس متناهی σ^2 :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu \quad \text{as } n \rightarrow \infty$$

(«همگرایی در احتمال»: $P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0$ برای هر $\varepsilon > 0$)

■ قانون قوی اعداد بزرگ

$$\bar{X}_n \xrightarrow{a.s.} \mu \quad \text{as } n \rightarrow \infty$$

(«همگرایی تقریباً مطمئن»: $P(\bar{X}_n \rightarrow \mu) = 1$)

■ اهمیت مهندسی

- ▶ میانگین نمونه با رشد اندازه نمونه به میانگین واقعی همگرا می‌شود
- ▶ برآورد میانگین‌ها از داده را توجیه می‌کند
- ▶ بنیاد شبیه‌سازی مونت کارلو (شبیه‌سازی بارها $\rightarrow$ میانگین همگرا می‌شود)
- ▶ این گزاره را توجیه می‌کند: «اگر به قدر کافی اندازه‌گیری کنم، میانگین من به مقدار واقعی نزدیک خواهد بود»

■ با چه سرعتی؟

بر اساس چبیشف: $P(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2 / (n\varepsilon^2)$

برای اطمینان ۹۵٪ از این که خطا $\varepsilon < \sigma^2 / (0.05 \cdot \varepsilon^2)$ باشد: به $n \geq \sigma^2 / (0.05 \cdot \varepsilon^2)$ نیاز است

۱۱.۳ قضیه حد مرکزی (CLT)

■ بیان صوری

برای $X_1, X_2, \dots, X_n$ مستقل و هم‌توزیع (i.i.d.) با میانگین μ و واریانس متناهی σ^2 :

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$$

■ شکل عملی

برای n بزرگ:

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$S_n = \sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$$

■ شرایط

۱. $X_1, \dots, X_n$ مستقل هستند
۲. هم‌توزیع هستند (با CLT لیپانوف/لیندهبرگ می‌توان این شرط را سست کرد)
۳. میانگین متناهی μ و واریانس متناهی σ^2
۴. n «به قدر کافی بزرگ» است (قاعده سرانگشتی: $n \geq 30$ ، اما به شکل توزیع بستگی دارد)

■ آنچه CLT نیاز ندارد

- ▶ نیاز ندارد X_i گاوسی باشد
- ▶ نیاز ندارد X_i پیوسته باشد
- ▶ نیاز ندارد هیچ توزیع خاصی داشته باشد

۱۱.۴ نرخ همگرایی

CLT با چه سرعتی «اثر می گذارد»؟

توزیع اصلی	n لازم برای تقریب خوب
متقارن (یکنواخت)	$n \approx 5-10$
کمی چوله	$n \approx 20-30$
به شدت چوله (نمایی)	$n \approx 30-50$
به غایت چوله	$n \approx 50-100+$

قاعده: توزیع های متقارن تر → همگرایی سریع تر.

۱۱.۵ نمایش بصری

■ جمع متغیرهای تصادفی یکنواخت → گاوسی

- ▶ $n=1$: یکنواخت (مسطح)
- ▶ $n=2$: مثلثی
- ▶ $n=3$: شروع به زنگوله‌ای شدن می‌کند
- ▶ $n=5$: تقریباً گاوسی
- ▶ $n=12$: عملاً از گاوسی قابل تفکیک نیست

■ جمع متغیرهای تصادفی نمایی → گاوسی

- ▶ $n=1$: نمایی (به شدت چوله به راست)
- ▶ $n=3$: همچنان چوله اما کمتر ($\text{Gamma}(3)$)
- ▶ $n=10$: تقریباً متقارن، زنگوله‌ای
- ▶ $n=30$: اساساً گاوسی

■ دوجمله‌ای → تقریب نرمال

$$\text{Binomial}(n, p) \approx N(np, np(1-p)) \text{ برای } n \text{ بزرگ}$$

این همان CLT اعمال شده به جمع آزمایش‌های برنولی است!

▶ تصحیح پیوستگی: $P(X \leq k) \approx \Phi((k + 0.5 - np)/(\sqrt{np(1-p)}))$

۱۱.۶ اهمیت مهندسی

■ چرا نویز حرارتی گاوسی است

نویز حرارتی = اثر تجمعی میلیاردها الکترون که به طور تصادفی حرکت می کنند. سهم هر الکترون ناچیز و مستقل است
CLT → اعمال می شود → نویز گاوسی است.

■ چرا تداخل تجمعی گاوسی است

در یک شبکه سلولی، تداخل کل = جمع سیگنال های بسیاری از کاربران مستقل. → CLT تداخل $\approx$ گاوسی (برای کاربران زیاد).

■ چرا خطاهای اندازه گیری گاوسی هستند

خطای کل = جمع بسیاری از منابع خطای کوچک و مستقل (کالیبراسیون، کوانتیزاسیون، گرمایی، لرزش و ...) → CLT → خطا $\approx$ گاوسی.

■ چرا تغییرات ساخت گاوسی هستند

مقدار مقاومت = مقدار نامی + جمع بسیاری از تغییرات کوچک فرایند (دوپینگ، حکاکی، دما و ...) → CLT → مقدار $\approx$ گاوسی حول مقدار نامی.

۱۱.۷ نمایش‌های مونت کارلوی MATLAB

مثال ۱: CLT با توزیع یکنواخت

```

MATLAB
%% CLT: Sum of Uniform RVs approaches Gaussian
N_experiments = 50000;
n_values = [1, 2, 5, 12, 30];

figure;
for idx = 1:length(n_values)
    n = n_values(idx);

    % Generate sum of n Uniform(0,1) RVs
    X = sum(rand(n, N_experiments), 1);

    % Standardize: Z = (X - nμ)/(σ√n) where μ=0.5, σ²=1/12
    mu_sum = n * 0.5;
    sigma_sum = sqrt(n / 12);
    Z = (X - mu_sum) / sigma_sum;

    subplot(2, 3, idx);
    histogram(Z, 60, 'Normalization', 'pdf');
    hold on;
    z = linspace(-4, 4, 200);
    plot(z, normpdf(z), 'r', 'LineWidth', 2);
    title(sprintf('n = %d', n));
    xlabel('Standardized Sum'); xlim([-4 4]);
    if idx == 1, ylabel('PDF'); end
end
sgtitle('CLT: Sum of Uniform RVs → Gaussian');

```

مثال ۲: CLT با توزیع نمایی

MATLAB

```

%% CLT: Sample Mean of Exponential(1) converges to Gaussian
lambda = 1; mu = 1; sigma = 1;
N_experiments = 100000;
n_values = [1, 3, 10, 30, 100];

figure;
for idx = 1:length(n_values)
    n = n_values(idx);

    % Generate sample means
    X = exprnd(1, n, N_experiments);
    X_bar = mean(X, 1);

    subplot(2, 3, idx);
    histogram(X_bar, 80, 'Normalization', 'pdf');
    hold on;
    x = linspace(0, max(X_bar), 200);
    plot(x, normpdf(x, mu, sigma/sqrt(n)), 'r', 'LineWidth', 2);
    title(sprintf('n = %d', n));
    xlabel('Sample Mean');
end
sgtitle('CLT: Mean of Exponential → Gaussian');

```

مثال ۳: تقریب نرمال دوجمله‌ای

MATLAB

```

%% Binomial(n,p) approximated by Gaussian
n = 50; p = 0.3;
k = 0:n;
pmf_binom = binopdf(k, n, p);

% Normal approximation
mu_approx = n*p;
sigma_approx = sqrt(n*p*(1-p));
pdf_normal = normpdf(k, mu_approx, sigma_approx);

figure;
bar(k, pmf_binom, 'FaceAlpha', 0.5);
hold on;
plot(k, pdf_normal, 'r-', 'LineWidth', 2);
xlabel('k'); ylabel('Probability');
title(sprintf('Binomial(%d, %.1f) vs Normal(%.1f, %.2f)', n, p, mu_approx,
    ↪ sigma_approx^2));
legend('Binomial (exact)', 'Normal approximation');

```

■ مثال ۴: نمایش کامل CLT با مونت کارلو

MATLAB

```

%% Full CLT demonstration: non-Gaussian → Gaussian via averaging
% Generate N samples from a VERY non-Gaussian distribution
% (mixture: 80% from Exp(1), 20% from Exp(0.1))
N_experiments = 100000;
n_samples = 50;

% Generate raw data
raw = zeros(n_samples, N_experiments);
for i = 1:N_experiments
    mask = rand(n_samples, 1) < 0.8;
    raw(mask, i) = exprnd(1, sum(mask), 1);
    raw(~mask, i) = exprnd(10, sum(~mask), 1);
end

% True mean and variance of mixture
mu_true = 0.8*1 + 0.2*10; % = 2.8
var_true = 0.8*(1+1^2) + 0.2*(100+10^2) - mu_true^2; % Second moment - mean^2

% Compute sample means
X_bar = mean(raw, 1);

figure;
subplot(2,1,1);
histogram(raw(:,1), 100, 'Normalization', 'pdf');
title('Original Distribution (highly skewed mixture)');
xlabel('X'); ylabel('PDF');

subplot(2,1,2);
histogram(X_bar, 100, 'Normalization', 'pdf');
hold on;
x = linspace(min(X_bar), max(X_bar), 200);
plot(x, normpdf(x, mu_true, sqrt(var_true/n_samples)), 'r', 'LineWidth', 2);
title(sprintf('Sample Mean (n=%d) - Gaussian by CLT!', n_samples));
xlabel('Sample Mean'); ylabel('PDF');
legend('Empirical', 'Gaussian approximation');

```

۱۱.۸ تقریب‌زنی با استفاده از CLT

■ رویه کلی

برای تقریب $P(S_n \leq x)$ که در آن $S_n = X_1 + \dots + X_n$:

۱. $\mu = E[X_i]$ ، $\sigma^2 = \text{Var}(X_i)$ را محاسبه کنید

$$S_n \approx N(n\mu, n\sigma^2) \quad ۲.$$

$$P(S_n \leq x) \approx \Phi((x - n\mu)/(\sigma\sqrt{n})) \quad ۳.$$

■ تصحیح پیوستگی (برای متغیرهای تصادفی گسسته)

هنگام تقریب‌زدن یک جمع گسسته با گاوسی:

$$P(X \leq k) \approx \Phi((k + 0.5 - n\mu)/(\sigma\sqrt{n})) \quad \blacktriangleright$$

$$P(X = k) \approx \Phi((k + 0.5 - n\mu)/(\sigma\sqrt{n})) - \Phi((k - 0.5 - n\mu)/(\sigma\sqrt{n})) \quad \blacktriangleright$$

مثال: خطاهای بسته

۱۰۰۰ بسته، احتمال خطای هر یک $0.02 = X$ = مجموع خطاها.

دقیق: $X \sim \text{Binomial}(1000, 0.02)$

تقریب CLT: $X \approx N(20, 19.6)$

$$P(X > 30) \approx 1 - \Phi((30.5 - 20)/\sqrt{19.6}) = 1 - \Phi(2.37) = 0.0089$$

۱۱.۹ مسایل تمرینی

مسئله ۱

یک کارخانه پیچ تولید می‌کند. طول $X \sim$ توزیعی با $\mu = 10\text{cm}$ و $\sigma = 0.2\text{cm}$. یک دسته ۱۰۰ پیچی اندازه‌گیری می‌شود.

(الف) توزیع تقریبی $\bar{X}$ چیست؟ (ب) $P(\bar{X} > 10.05)$ ؟ (ج) $P(9.96 < \bar{X} < 10.04)$ ؟

حل

(الف) $\sigma_{\bar{X}} = 0.02$, $\bar{X} \sim N(10, 0.04/100) = N(10, 0.0004)$

(ب) $P(\bar{X} > 10.05) = P(Z > 2.5) = 0.0062$

(ج) $P(9.96 < \bar{X} < 10.04) = \Phi(2) - \Phi(-2) = 0.9545$

مسئله ۲

یک لینک مخابراتی ۱۰۰۰۰ بیت با $\text{BER} = 0.001$ دارد. با استفاده از CLT مقدار (بیش از ۱۵ خطا) P را تقریب بزنید.

$\sigma^2=9.99$, $\mu=10$, $X \sim \text{Binomial}(10000, 0.001)$ **حل**

$P(X > 15) \approx 1 - \Phi((15.5-10)/\sqrt{9.99}) = 1 - \Phi(1.74) = 0.0409$

مسئله ۳

کد MATLAB را برای بررسی CLT برای توزیع کای دو (۱) (بسیار چوله) بنویسید و همگرایی را برای $n=2,5,10,50$ نشان دهید.

حل

```
MATLAB
N = 100000; ns = [2 5 10 50];
figure;
for i = 1:4
    X_bar = mean(chi2rnd(1, ns(i), N), 1);
    subplot(2,2,i);
    histogram(X_bar, 80, 'Normalization', 'pdf'); hold on;
    x = linspace(0, 3, 200);
    plot(x, normpdf(x, 1, sqrt(2/ns(i))), 'r', 'LineWidth', 2);
    title(sprintf('n=%d', ns(i)));
end
sgtitle('CLT for  $\chi^2(1)$ : Mean→Gaussian');
```

ماژول بعدی: ماژول ۱۲ — مقدمه‌ای بر آمار